

## **DESCOMPOSICIÓN SVD**

ALAN REYES-FIGUEROA  
MÉTODOS NUMÉRICOS II

(AULA 04) 13.JULIO.2023


# Descomposición SVD

La descomposición en valores singulares, SVD, está motivada por el siguiente hecho geométrico:

La imagen de la esfera unitaria bajo cualquier matriz en  $\mathbb{R}^{m \times n}$  es una hiperelipse en  $\mathbb{R}^m$ , obtenida al “estirar” la esfera unitaria en  $\mathbb{R}^m$  por algunos factores  $\sigma_1, \dots, \sigma_m$ , (posiblemente cero) en algunas direcciones ortogonales  $\mathbf{u}_1, \dots, \mathbf{u}_m \in \mathbb{R}^m$ .

Por conveniencia, consideramos que los  $\mathbf{u}_i$  son vectores unitarios, es decir,  $\|\mathbf{u}_i\|_2 = 1$ . Los vectores  $\{\sigma_i \mathbf{u}_i\}$  son los semi-ejes principales de la hiperelipse, con longitudes  $\sigma_1, \dots, \sigma_m$ . Si  $A$  tiene rango  $r$ , exactamente  $r$  de estas longitudes resultarán ser distintas de cero, y en particular, si  $m > n$ , como máximo  $n$  de ellas serán distinto de cero.

# Descomposición SVD



SVD de una matriz en  $\mathbb{R}^{2 \times 2}$ .

Sea  $S = S^{n-1}$  la esfera unitaria en  $\mathbb{R}^n$ , y tome cualquier matriz  $A \in \mathbb{R}^{m \times n}$  con  $m > n$ . Por simplicidad, supongamos que  $A$  tiene rango completo  $n$ . La imagen  $AS$  es una hiperelipse en  $\mathbb{R}^m$ .

Definimos algunas propiedades de  $A$  en términos de la forma de  $AS$ .

# Descomposición SVD

Primero, definimos los  $n$  **valores singulares** de  $A$ . Estos son las longitudes de los  $n$  semi-ejes principales de  $AS$ , escritos  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n > 0$ .

Los  $n$  **vectores singulares izquierdos** de  $A$ . Estos son los vectores unitarios  $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n\}$  orientados en las direcciones de los semi-ejes principales de  $AS$ , numerados para corresponder con los valores singulares. Así,  $\sigma_i \mathbf{u}_i$  es el  $i$ -ésimo mayor semi-eje principal de  $AS$ .

Finalmente, los  $n$  **vectores singulares derechos** de  $A$  son los vectores unitarios  $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\} \subset S$  que son las preimágenes de los semi-ejes principales de  $AS$ , numerados de modo que  $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$ ,  $i = 1, 2, \dots, n$ .

De lo anterior tenemos una relación entre los  $\sigma_i$ , los  $\mathbf{u}_i$  y los  $\mathbf{v}_i$ :

# Descomposición SVD

$$A\mathbf{v}_j = \sigma_j \mathbf{u}_j, \forall 1 \leq j \leq n. \quad (1)$$

Esta colección de ecuaciones vectoriales se puede expresar como una ecuación matricial, como

$$A \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \cdots & u_n \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix}$$

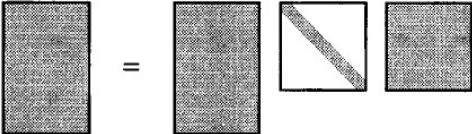
o de forma más compacta como  $AV = \hat{U}\hat{\Sigma}$ , con  $\hat{U} \in \mathbb{R}^{m \times n}$ ,  $V, \hat{\Sigma} \in \mathbb{R}^{n \times n}$ .  $V \in O(n)$  es ortogonal, mientras que  $\hat{U}$  posee columnas ortogonormales.

Como  $V$  es ortonormal, podemos escribir  $A = \hat{U}\hat{\Sigma}V^T$ .

# Descomposición SVD

## Definición

La factoración  $A = \hat{U}\hat{\Sigma}V^T$  se llama la **descomposición en valores singulares reducida** de  $A$ .


$$A = \hat{U} \hat{\Sigma} V^*$$

Descomposición SVD reducida, (para  $m \geq n$ ).

Introducimos una segunda factorización SVD. La idea es la siguiente. Las columnas de  $\hat{U}$  son  $n$  vectores ortonormales en el espacio  $\mathbb{R}^m$ . A menos que  $m = n$ , no forman una base de  $\mathbb{R}^m$ , ni  $\hat{U}$  es una matriz ortogonal.

# Descomposición SVD

Adjuntamos  $m - n$  columnas ortonormales adicionales, de modo que  $\hat{U}$  se extiende a una matriz ortogonal  $U$ . Si  $\hat{U}$  se reemplaza por  $U$  en (1),  $\hat{\Sigma}$  también cambia. Para que el producto permanezca inalterado, las últimas  $m - n$  columnas de  $U$  deben multiplicarse por cero. En consecuencia, sea  $\Sigma$  la matriz  $m \times n$  que consta de  $\hat{\Sigma}$  en el bloque  $n \times n$  superior junto con  $m - n$  filas de ceros a continuación.

Ahora tenemos una nueva factoración de la forma  $AV = U\Sigma$  ó  $A = U\Sigma V^T$ , donde  $\hat{U} \in \mathbb{R}^{m \times m}$ ,  $V \in \mathbb{R}^n$  y  $\Sigma \in \mathbb{R}^{m \times n}$ . Además,  $V \in O(n)$  y  $U \in O(m)$  son matrices ortogonales.

# Descomposición SVD

## Definición

La factoración  $A = U\Sigma V^T$  se llama la **descomposición en valores singulares completa** de  $A$ .

$A = U \Sigma V^*$

Descomposición SVD completa, (para  $m \geq n$ ).

Habiendo descrito la SVD completa, ahora podemos descartar el supuesto inicial que  $A$  tiene rango completo. Si  $A$  es deficiente en rango, i.e.  $\text{rank}(A) = r < \min\{m, n\}$ , la factoración SVD completa aún es válida.



# Descomposición SVD

Todo lo que cambia es que ahora no  $n$  sino solo  $r$  de los vectores singulares izquierdos de  $A$  están determinados por la geometría de la hiperelipse. Al construir la matriz ortogonal  $U$ , añadimos  $m - r$  en lugar de  $m - n$  columnas ortonormales adicionales. La matriz  $V$  también necesitará  $n - r$  columnas ortonormales adicionales para extender las  $r$  columnas determinadas por la geometría.

La matriz  $\Sigma$  ahora tendrá  $r$  entradas diagonales positivas, con las  $n - r$  restantes igual a cero. De la misma manera, la SVD reducida también tiene sentido para matrices  $A$  de rango deficiente. Se puede tomar  $\hat{U}$  como  $m \times n$ , con  $\hat{\Sigma}$  de dimensiones  $n \times n$  con algunos ceros en la diagonal, o comprimir aún más la representación de modo que  $\hat{U}$  sea  $m \times r$  y  $\hat{\Sigma}$  sea  $r \times r$  y estrictamente positiva en la diagonal.

## Teorema (Existencia y unicidad SVD)

*Toda matriz  $A \in \mathbb{C}^{m \times n}$  posee una descomposición en valores singulares  $A = U^*$ . Además, los valores singulares  $\{\sigma_j\}$  se determinan unívocamente y, si  $A$  es cuadrada y los  $\sigma_j$  son distintos, los vectores singulares izquierdos y derechos  $\{\mathbf{v}_j\}$  y  $\{\mathbf{u}_j\}$  se determinan de forma única hasta signos complejos (es decir, factores escalares complejos de módulo 1).*

Prueba. Para probar la existencia de la SVD, procedemos por inducción sobre la dimensión de  $A$ .

Hagamos  $\sigma_1 = \|A\|_2$ . Como  $S = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_2 = 1\}$  es compacto, existe un vector  $\mathbf{v}_1 \in \mathbb{R}^n$  con  $\|\mathbf{v}_1\|_2 = 1$ , y  $\|\mathbf{u}_1\|_2 = \sigma_1$ , tales que  $\mathbf{u}_1 = A\mathbf{v}_1$ .

Extendemos  $\mathbf{v}_1$  a una base ortonormal  $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$  de  $\mathbb{R}^n$ , y  $\mathbf{u}_1$  a una base

# Descomposición SVD

$\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$  ortonormal de  $\mathbb{R}^m$ . Sean  $U_1$  y  $V_1$  las matrices ortogonales con columnas  $\mathbf{u}_i$  y  $\mathbf{v}_i$ , respectivamente.

Tenemos

$$U^T \Sigma V = S = \begin{pmatrix} \sigma_1 & \mathbf{w}^T \\ \mathbf{o} & B \end{pmatrix},$$

donde  $\mathbf{w}^T$  es un vector fila,  $\mathbf{o}$  es un vector columna y  $B \in \mathbb{R}^{(m-1) \times (n-1)}$ . Además

$$\left\| \begin{pmatrix} \sigma_1 & \mathbf{w}^T \\ \mathbf{o} & B \end{pmatrix} \begin{pmatrix} \sigma_1 \\ \mathbf{w} \end{pmatrix} \right\|_2 \geq \sigma_1^2 + \mathbf{w}^T \mathbf{w} = (\sigma_1^2 + \mathbf{w}^T \mathbf{w})^{1/2} \left\| \begin{pmatrix} \sigma_1 \\ \mathbf{w} \end{pmatrix} \right\|_2,$$

de modo que  $\|S\|_2 \geq (\sigma_1^2 + \mathbf{w}^T \mathbf{w})^{1/2}$ .

Como  $U_1$  y  $V_1$  son ortogonales, sabemos que  $\|S\|_2 = \|A\|_2 = \sigma_1$ , y esto implica que  $\mathbf{w} = \mathbf{o}$ .

# Descomposición SVD

Si  $n = 1$  ó  $m = 1$ , acabó la prueba. De lo contrario, la submatriz  $B$  describe la acción de  $A$  en el subespacio ortogonal a  $\langle \mathbf{v}_1 \rangle$ , un espacio de dimensión  $n - 1$ .

Por la hipótesis de inducción,  $B$  admite una descomposición SVD de la forma  $B = U_2 \Sigma_2 V_2^T$ , y se verifica que

$$A = U_1 \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & U_2 \end{pmatrix} \begin{pmatrix} \sigma_1 & \mathbf{0} \\ \mathbf{0} & \Sigma_2 \end{pmatrix} \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & V_2 \end{pmatrix}^T V_1^T.$$

es una descomposición SVD para  $A$ , como queríamos. Esto muestra la existencia.

Para la unicidad, leer el final del capítulo 4, libro de Trefethen.  $\square$

# Cambio de Bases

La SVD nos permite decir que cada matriz es diagonal, desde que se utilicen las bases adecuadas para los espacios de dominio y rango.

Dado cualquier  $\mathbf{b} \in \mathbb{R}^m$ ,  $\mathbf{b}$  puede expandirse en la base de los vectores singulares izquierdos de  $A$  (columnas de  $U$ ), y cualquier  $\mathbf{x} \in \mathbb{R}^n$  puede representarse en la base de los vectores singulares derechos de  $A$  (columnas de  $V$ ).

Los vectores de coordenadas para estas expansiones son  $\mathbf{b}' = U^T \mathbf{b}$  y  $\mathbf{x}' = V^T \mathbf{x}$ . De  $A = U \Sigma V^T$ , la relación  $\mathbf{b} = A \mathbf{x}$  se puede expresar en términos de  $\mathbf{b}'$  y  $\mathbf{x}'$  como

$$\mathbf{b} = A \mathbf{x} \Leftrightarrow U^T \mathbf{b} = U^T A = U^T U \Sigma V^T \mathbf{x} \Leftrightarrow \mathbf{b}' = \Sigma \mathbf{x}'.$$

Así,  $A$  se reduce a la matriz diagonal  $\Sigma$  cuando el rango se expresa en la base de columnas de  $U$  y el dominio en la base de columnas de  $V$ .

# SVD y Descomposición Espectral

Una matriz cuadrada  $A$  de rango completo puede expresarse como una matriz diagonal de autovalores  $A$ , si el rango y el dominio están representados en una base de autovectores.

Relación entre la SVD y la Descomposición espectral:

Sea  $A = U\Sigma V^T$  la SVD de  $A$ . Entonces

$$A^T A = (U\Sigma V^T)^T (U\Sigma V) = V\Sigma(U^T U)\Sigma V^T = V\Sigma^2 V^T = V\Lambda V^T$$

- $\Rightarrow$  las columnas de  $V$  son los autovectores de  $A^T A$ ,
- $\Rightarrow$  los valores singulares  $\sigma_i$  son las raíces de los autovalores  $\lambda_i$  de  $A^T A$ .

$$A A^T = (U\Sigma V^T)(U\Sigma V)^T = U\Sigma(V^T V)\Sigma U^T = U\Sigma^2 U^T = U\Lambda U^T$$

- $\Rightarrow$  las columnas de  $U$  son los autovectores de  $A A^T$ ,
- $\Rightarrow$  los valores singulares  $\sigma_i$  son las raíces de los autovalores  $\lambda_i$  de  $A A^T$ .

# Propiedades a partir de la SVD

Sea  $A = U\Sigma V^T$  su descomposición en valores singulares.

Las pruebas de los resultados siguientes están en el Capítulo 5 de Trefethen.

## Teorema

*El rango  $\text{rank}(A)$  es  $r$ , el número de valores singulares no-nulos.*

## Teorema

$\text{Im}(A) = \langle \mathbf{u}_1, \dots, \mathbf{u}_r \rangle$  y  $\text{Ker}(A) = \langle \mathbf{v}_{r+1}, \dots, \mathbf{v}_n \rangle$ .

## Teorema

$\|A\|_2 = \sigma_1$  y  $\|A\|_F = \sqrt{\sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2}$ .

# Propiedades a partir de la SVD

## Teorema

Los valores singulares no-nulos de  $A$  son las raíces de los autovalores de  $A^T A$  o de  $AA^T$ . Esto es  $\sigma_i = \sqrt{\lambda_i}$ , donde  $\Lambda = (\lambda_1, \dots, \lambda_r, \dots)$  corresponde a la diagonal en la descomposición espectral de  $A^T A$  o de  $AA^T$ .

## Teorema

Si  $A = A^T$ , los valores singulares de  $A$  son los valores absolutos  $\sigma_i = |\lambda_i|$  de los autovalores de  $A$ .

## Teorema

Para  $A \in \mathbb{R}^{n \times n}$ , vale  $\det(A) = \prod_{i=1}^n \sigma_i$ .



# Aproximaciones de bajo rango

## Teorema (Eckart-Young)

Sea  $A \in \mathbb{R}^{n \times d}$ ,  $n \geq d$ , una matriz cuya descomposición SVD está dada por

$$A = USV^T = \sum_{i=1}^d \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

Entonces, la matriz  $\hat{A}_r$  de rango  $r$ ,  $1 \leq r \leq d$ , que mejor aproxima  $A$  en el sentido de minimizar

$$\min_{\text{rank } \hat{A}_r \leq r} \|A - \hat{A}_r\|_F^2$$

se obtiene de truncar la descomposición en valores singulares de  $A$ :

$$\hat{A}_r = U_r S_r V_r^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T,$$

# Aproximaciones de bajo rango

## Teorema (Eckart-Young)

donde

$$U_r = [\mathbf{u}_1 \ \mathbf{u}_2 \ \dots \ \mathbf{u}_r], \quad S_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r), \quad V_r = [\mathbf{v}_1 \ \mathbf{v}_2 \ \dots \ \mathbf{v}_r].$$

En ese caso, el error de aproximación está dado por

$$\|A - \hat{A}_r\|_F^2 = \sum_{i=r+1}^d \lambda_i,$$

o

$$\|A - \hat{A}_r\|_2^2 = \lambda_{r+1}.$$

# Descomposición de Schur

Otra factorización matricial, en realidad la que es más útil en análisis, es la llamada factoración de Schur.

## Definición

Una **factoración de Schur** de una matriz  $A \in \mathbb{R}^{n \times n}$  es una factorización de la forma

$$A = QTQ^T,$$

donde  $Q$  es ortogonal (unitaria) y  $T$  es triangular superior.

Observe que  $A$  y  $T$  son semejantes. De manera similar, los autovalores de  $A$  necesariamente aparecen en la diagonal de  $T$ .

## Teorema

*Toda matriz cuadrada  $A$  posee una factoración de Schur.*

# Descomposición de Schur

Prueba: Por inducción sobre la dimensión  $n$  de  $A$ .

El caso  $n = 1$  es directo, ya que  $A = [a] = [1][a][1]^T$ , así que suponga que  $n \geq 2$ . Sea  $\mathbf{x} \in \mathbb{R}^n$  cualquier autovector de  $A$ , con autovalor correspondiente  $\lambda$ .

Tomamos  $\mathbf{u}_1 = \frac{\mathbf{x}}{\|\mathbf{x}\|_2}$  normalizado, y lo hacemos la primer columna de la matriz  $U$ .

Entonces, al igual que en la descomposición espectral, vale

$$U^T A U = \begin{pmatrix} \lambda & B \\ \mathbf{0} & C \end{pmatrix},$$

con  $B \in \mathbb{R}^{n-1}$ ,  $C \in \mathbb{R}^{(n-1) \times (n-1)}$ .

De la hipótesis inductiva, existe una factoración de Schur  $V V^T$  para  $C$ . Escribimos entonces

# Descomposición de Schur

$$Q = U \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & V \end{pmatrix}.$$

Entonces,  $Q$  es una matriz ortogonal (unitaria), pues  $QQ^T = U \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & VV^T \end{pmatrix} U^T = UU^T = I$ , y tenemos

$$Q^T A Q = \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & V^T \end{pmatrix} U^T A U \begin{pmatrix} 1 & \mathbf{0} \\ \mathbf{0} & V \end{pmatrix} = \begin{pmatrix} \lambda & BV \\ \mathbf{0} & T \end{pmatrix} \Rightarrow A = Q \begin{pmatrix} \lambda & BV \\ \mathbf{0} & T \end{pmatrix} Q^T. \square$$

En resumen:

- Una diagonalización  $A = X\lambda X^{-1}$  existe, si y sólo si,  $A$  es no defectuosa.
- Una diagonalización unitaria existe, si y sólo si,  $A$  es **normal** (esto es,  $AA^* = A^*A$ ).
- Una descomposición SVD  $A = U\Sigma V^T$  siempre existe.
- Una descomposición de Schur  $A = QTQ^T$  siempre existe.