

## **DISTRIBUCIONES MULTIVARIADAS**

ALAN REYES-FIGUEROA  
MÉTODOS NUMÉRICOS II

(AULA 05A) 18.JULIO.2023

# Distribuciones multivariadas

Sea  $X = (X_1, X_2, \dots, X_d) \in \mathbb{R}^d$  un vector aleatorio (esto es, cada componente  $X_i$  es una variable aleatoria  $X_i : \Omega \rightarrow \mathbb{R}$ ).

## Definición

Definimos el **valor esperado** de  $X$  como el vector  $\mu \in \mathbb{R}^d$  dado por

$$\mathbb{E}(X) = \mu = (\mu_1, \mu_2, \dots, \mu_d)^T \in \mathbb{R}^d,$$

donde  $\mu_i = \mathbb{E}(X_i)$ , para  $i = 1, 2, \dots, d$ .

## Definición

Definimos la **varianza** de  $X$  como la matriz  $\Sigma \in \mathbb{R}^{d \times d}$  dada por

$$\text{Cov}(X) = \Sigma = (\text{Cov}(X_i, X_j))_{i,j}.$$

La entrada  $(i, j)$  de esta matriz corresponde a la covarianza de las variables  $X_i$  y  $X_j$ . A  $\Sigma$  también se le conoce como la **matriz de covarianza** de  $X$ .

# Distribuciones multivariadas

Para cualquier vector aleatorio  $X \in \mathbb{R}^d$ , la matriz de covarianzas  $\Sigma = \text{Cov}(X)$  satisface

1.  $\Sigma$  es simétrica (como consecuencia, tiene autovalores reales).
2.  $\Sigma$  es semi-definida positiva (todos sus autovalores son no-negativos).  
En particular, para todo vector  $\mathbf{x} \in \mathbb{R}^d$ , se cumple que  $\mathbf{x}^T \Sigma \mathbf{x} \geq 0$ .
3. La diagonal de  $\Sigma$  contiene a las varianzas  $\sigma_i^2 = \text{Cov}(X_i)$ , para  $i = 1, 2, \dots, d$ .
4. Si  $\mathbb{X} \in \mathbb{R}^{n \times d}$  es la matriz de datos. Entonces  $\Sigma = \mathbb{X}^T \mathbb{X}$ .

# Distribuciones multivariadas

Sea  $X_1, X_2, \dots, X_n \in \mathbb{R}^d$  es una muestra aleatoria de vectores i.i.d (independientes e idénticamente distribuidos), todos con distribución  $X$ .

Podemos codificar esta muestra dentro de una matriz,  $\mathbb{X} \in \mathbb{R}^{n \times d}$ , llamada la **matriz de datos** (cada dato de la muestra es un renglón de  $\mathbb{X}$ ).

$$\mathbb{X} = \begin{pmatrix} X_{11} & X_{12} & \dots & X_{1d} \\ X_{21} & X_{22} & \dots & X_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{nd} \end{pmatrix},$$

donde

$$X_i = (x_{i1}, x_{i2}, \dots, x_{id}) \in \mathbb{R}^d, \quad i = 1, 2, \dots, n.$$

# Distribuciones multivariadas

Observe que la  $i$ -ésima columna de  $\mathbb{X}$  corresponde a una muestra (de tamaño  $n$ ) de la variable aleatoria  $X_i$ . Podemos entonces restar a cada columna su correspondiente media  $\mu_i = \mathbb{E}(X_i)$ . Así, obtenemos una versión centrada de la matriz de datos:

$$\mathbb{X}_c = \mathbb{X} - \mu = \begin{pmatrix} X_{11} - \mu_1 & X_{12} - \mu_2 & \dots & X_{1d} - \mu_d \\ X_{21} - \mu_1 & X_{22} - \mu_2 & \dots & X_{2d} - \mu_d \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} - \mu_1 & X_{n2} - \mu_2 & \dots & X_{nd} - \mu_d \end{pmatrix}.$$

Es posible mostrar (con las propiedades de la página siguiente) que la matriz de covarianzas empírica (muestral) se puede escribir como

$$\Sigma = \text{Cov}(X) = \mathbb{X}_c^T \mathbb{X}_c.$$

# Distribuciones multivariadas

Sea  $X, Y \in \mathbb{R}^d$  vectores aleatorios,  $a, b \in \mathbb{R}$ ,  $c \in \mathbb{R}^d$  constantes,  $A \in \mathbb{R}^{p \times d}$  una matriz constante. Entonces

1.  $\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y)$ ,
2.  $\mathbb{E}(c) = c$ ,
3.  $\mathbb{E}(\mathbb{E}(X)) = \mathbb{E}(X)$ ,
4.  $\text{Cov}(aX) = a^2 \text{Cov}(X)$ ,
5.  $\text{Cov}(\mathbf{A}\mathbf{X}) = \mathbf{A}^T \text{Cov}(\mathbf{X})\mathbf{A}$ ,
6.  $\text{Cov}(aX + bY) = a^2 \text{Cov}(X) + b^2 \text{Cov}(Y) + 2ab\text{Cov}(X, Y)$ ,
7. Si  $X \perp Y$ , entonces  $\text{Cov}(X, Y) = \mathbf{0}$ ,
8. Si  $X \perp Y$ , entonces  $\text{Cov}(aX + bY) = a^2 \text{Cov}(X) + b^2 \text{Cov}(Y)$ .

# Distribución normal multivariada

Sea  $X = (X_1, X_2, \dots, X_d) \in \mathbb{R}^d$  un vector aleatorio. Decimos que  $X$  sigue una **distribución normal multivariada**  $\mathcal{N}_d(\mu, \Sigma)$  si su densidad está dada por

$$f_X(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} \det(\Sigma)^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right) d\mathbf{x}.$$



Aquí,

$$\mathbb{E}(X) = \mu = (\mu_1, \mu_2, \dots, \mu_d)^T,$$

y

$$\text{Cov}(X) = \Sigma = \begin{pmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_d) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \dots & \text{Cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \text{Cov}(X_d, X_2) & \dots & \text{Cov}(X_d, X_d) \end{pmatrix}.$$

# Distribución normal multivariada



Densidad de una normal bivariada: (a) como nube de puntos, (b) como función.



# Distribución normal multivariada


Típicamente la matriz  $\Sigma$  proporciona información sobre la relación entre las variables componentes.

$Cov(X) = [Cov(X_i, X_j)]$  es una matriz simétrica y pos. definida.

Caso  $d = 2$ :

$$\begin{pmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_1, X_2) & Var(X_2) \end{pmatrix} = \begin{pmatrix} \sigma_{X_1}^2 & Cor(X_1, X_2)\sigma_{X_1}\sigma_{X_2} \\ Cor(X_1, X_2)\sigma_{X_1}\sigma_{X_2} & \sigma_{X_2}^2 \end{pmatrix}$$


Cambiar  $\rho = Cor(X_1, X_2)$ :



<http://personal.kenyon.edu/hartlaub/MellonProject/images/Bivariate52.gif>

# Distribución normal multivariada

Una forma práctica de ver esta información de covarianza o correlación entre las componentes es a través de *pair-plots*.



Pairplot de una muestra para una normal 3-variada.

# Distribución normal multivariada

¿Cómo generar una muestra de una distribución normal  $d$ -variada con  $\mu$  y  $\Sigma$  específicas?

Algoritmo (o receta):

1. Generar  $d$  muestras (de tamaño  $n$ ), independientes, de distribuciones normales estándar  $Z_1, Z_2, \dots, Z_d \in \mathbb{R}^n$ , y construir una matriz de datos  $\mathbb{Z}$  con las muestras  $Z_i$  como columnas.

Como son independientes y estándar el vector  $Z = (Z_1, \dots, Z_d)$  sigue una distribución normal estándar  $\mathcal{N}_d(\mathbf{0}, I_d)$ .

2. Asegurarse que la matriz  $\Sigma$  es simétrica y positiva definida. Luego, construir descomposición de Cholesky  $L^T L = \Sigma$ , (veremos este algoritmo más adelante).

3. Construir la variable aleatoria  $X = LZ + \mu$ , la cual tiene una matriz de datos dada por  $\mathbb{X} = L\mathbb{Z} + \mu$  (la muestra que queremos). De las propiedades anteriores, tenemos que  $\mathbb{E}(Z) = \mu$  y  $\text{Cov}(X) = L^T I_d L = L^T L = \Sigma$ .